

Raport testowanie i optymalizacja kodu

3.

W celu przyspieszenia procesu uczenia modelu ResNet50 przeprowadzono porównanie czasu treningu na procesorze CPU oraz akceleratorze GPU w środowisku Google Colab. Przeprowadzono również porównanie między klasycznym trenowaniem modelu od zera a podejściem z transfer learningiem.

Wersja modelu	Czas treningu	Walidacyjna dokładność
ResNet50 (CPU)	316.59s	42.85%
ResNet50 (GPU)	118.85s	52.38%
ResNet50 + transfer	25.94s	90.48%


Wnioski 3a:

- Trening na GPU był znacząco szybszy – nawet kilkukrotnie w porównaniu do CPU.


Wnioski 3b:

- Transfer learning pozwolił uzyskać wysoką dokładność znacznie szybciej.
- Dzięki zamrożeniu wag wcześniejszych warstw sieci trenowana była tylko końcówka, co znacząco obniżyło koszt obliczeniowy.


Wykres bez GPU:



Wykres z GPU:




Wykres z transfer learningiem:



Wersja modelu	Czas treningu	Walidacyjna dokładność
Z normalizacją	22.63s	66.67%

Z normalizacja




- z augmentacją w warstwie wejściowej (RandomFlip, RandomRotation, RandomZoom)

Wersja modelu	Czas treningu	Walidacyjna dokładność
Z augmentacją	24.84s	90.48%

Z augmentacją:

TRANSFER LEARNING – ResNet50 (zamrożony) z augmentacją (bez normalizacji)
Czas treningu: 24.84 s
Dokładność treningowa: 100.00%
Dokładność walidacyjna: 90.48%



- **Nie wpłynęło na poprawę dokładności** modelu – może to wynikać z dobrej jakości i jednolitości zbioru danych (np. sztuczne zdjęcia piłek na jednolitym tle).
- Augmentacja **nie zaszkodziła modelowi**, co oznacza, że nadal jest bezpieczną i potencjalnie przydatną techniką.


4c

Celem eksperymentu było zbadanie wpływu zastosowania warstwy **Dropout**. Dropout to technika regularyzacji, która losowo „wyłącza” część neuronów podczas treningu, co pomaga zmniejszyć przeuczenie (overfitting).

W tym eksperymencie zastosowano Dropout (0.3) po warstwie gęstej (Dense(128)) i porównano wyniki z wersją modelu bez Dropoutu.

Wersja modelu	Czas treningu	Walidacyjna dokładność
Z dropoutem	24.31s	90.48%

Z dropoutem:




Wnioski 4c:

- **Czas treningu był nieco krótszy z Dropoutem** – może to wynikać z faktu, że model efektywnie trenował mniejszą liczbę aktywnych neuronów w każdej epoce.

4d

Rozmiar wejściowy	Czas treningu	Walidacyjna dokładność
96x96	30.16s	85.71%
160x160	26.0s	90.48%
224x224	23.42 s	90.48%




4f:

W ramach eksperymentu sprawdzono wpływ wartości `batch_size` na czas treningu i dokładność modelu. `Batch size` określa, ile próbek jednocześnie przetwarzane jest podczas jednej iteracji treningu.

Przetestowano trzy wartości:

- 32
- 64
- 128

Rozmiar batcha	Czas treningu	Walidacyjna dokładność
32	24.07 s	90.48%
64	23.43s	90.48%
128	104.64s	90.48%



4g - testowanie różnych struktur sieci

PODSUMOWANIE - różne architektury:

VGG16 → Train Acc: 100.00%, Val Acc: 90.48%, Time: 43.57s

ResNet101 → Train Acc: 100.00%, Val Acc: 95.24%, Time: 46.50s

InceptionV3 → Train Acc: 66.67%, Val Acc: 61.90%, Time: 37.45s

MobileNetV2 → Train Acc: 97.62%, Val Acc: 85.71%, Time: 21.14s

